Contextualização

Tenho uma série de projetos pessoais que eu gostaria de implementar, que precisam de uma base de dados alimentada com o conteúdo de cupons fiscais (impresso em papel térmico, por exemplo; num caixa de supermercado, posto de combustível, etc). A entrada de dados nessa pilha de processamento é o cupom fiscal físico, que precisa ser digitalizado, passar por um OCR, e por fim uma extração de dados estruturada. Esses dados extraídos ainda não estariam prontos para alimentar a base de dados, e precisam ser curados. Digamos que a conversão de dado bruto para dados estruturados prontos para consumo foi feita perfeitamente.

Para alimentar a base de dados, os dados de interesse nos cupons são data da transação, nome do estabelecimento, e, principalmente, a discriminação dos itens comprados. Cada item nessa discriminação tem, em geral, um código de estoque (que não importa pra base de dados), uma descrição altamente truncada que cada comércio faz de um jeito diferente, quantidade, valor unitário e subtotal. O desafio geral é de converter essa descrição truncada para uma descrição detalhada (produto, marca e submarca, tamanho da embalagem, etc).

O trabalho proposto para a disciplina é derivado como uma fatia pequena e restrita desse desafio geral, com domínio tão próximo quanto possível, em função da disponibilidade de dados. Além do motivo prático imediato de alcançar aprovação na disciplina, mesmo que o domínio do trabalho não se alinhe perfeitamente, a prática será importante para a implementação futura da base de dados e projetos associados.

Dataset, problema desenhado, observações

Para viabilizar o trabalho, pesquisei datasets existentes que se alinhem com o problema descrito. Agora, para fins da descrição da proposta do trabalho, esqueça os problemas originais; a não ser que exista um dataset que viabilize aprendizado supervisionado exatamente no domínio original, muda-se o problema para o que for viável com o dataset.

ELEVEN Data-Set
https://github.com/vinidiol/descmerc
https://www.scitepress.org/Papers/2022/115248/115248.pdf

Dos datasets encontrados, é o de domínio mais próximo do problema motivador. Ele viabiliza aprendizado supervisionado de classificação; O dataset traz uma coluna XPROD, que é análoga à descrição truncada que ocorre em cupons fiscais, e uma coluna NCM (Nomenclatura Comum do Mercosul). O objetivo seria treinar um modelo que, dada XPROD como entrada, prediz NCM. O dataset possui ~1.1 milhão de linhas com nenhum valor nulo.

A abordagem que, a priori, parece mais promissora é aplicar uma CNN. Essa abordagem também pode ser comparada com outras técnicas de classificação vistas no decorrer da disciplina, em particular árvores de decisão.

O github também traz alguns códigos de referência, e o artigo publicado já dá um caminho inicial para encontrar trabalhos relacionados, e resultados da literatura para comparar com o obtido, dando peso aos aspectos de escrita científica do trabalho da disciplina.